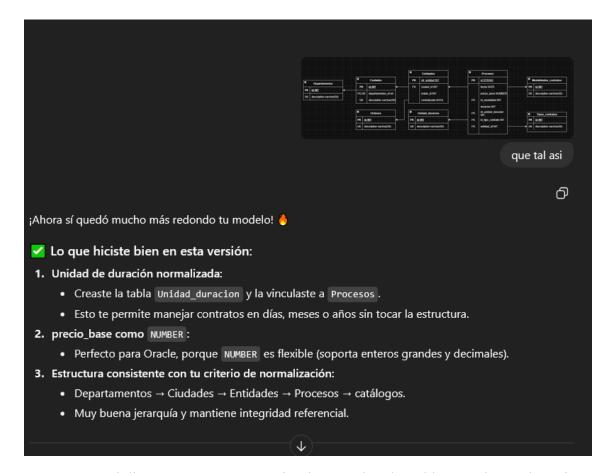


Se verifica que el esquema de base de datos tenga todos los puntos cubiertos para no tener problemas en el proceso de implementación, luego con algunas correcciones se vuelve a promtear



Una vez con el diagrama correctamente implementado y las tablas creadas en datagrip se hace ajustes:

que tal si el campo duracion lo normalizamos solo en dias, sabiiendo que la tabla original tiene informacion en una columna un numero de duracion y en otra (unidad_duracion) donde dice dias o meses, es posible volver a hacer este proceso pero poblando la estadistica de duracion solo a dias?

¡Muy buena idea! 🙌

Sí es totalmente posible. De hecho, es un **caso típico en ETL**: convertir todos los valores a una **unidad estándar** (en este caso **días**), y así ya no necesitas mantener la tabla Unidad_duracion .

📌 Estrategia

- 1. Mantener en staging (Esquema_sin_corregir) el dato tal cual del CSV:
 - duracion (número)
 - unidad_duracion (ej: "día(s)", "mes(es)").
- 2. Al poblar tu tabla Procesos, convertir la duración a días:
 - Si unidad_duracion = "día(s)" → dejar el valor igual.
 - Si unidad_duracion = "mes(es)" → multiplicar por 30 (o 31, o usar un promedio como 30.44).
 - Si unidad_duracion = "año(s)" → multiplicar por 365.

(Tú decides la regla de conversión que más se ajuste a tu negocio.)

3. En el modelo final ya no necesitas Unidad_duracion, solo guardas duracion_dias.

A Cambios en la tabla Procesos

Luego se le piide llenar las tablas en base al csv que se envia para poder dar completo entendimiento a la naturaleza de los datos

la tabla staging saco errores, se cuales son pero te quiero mandar el csv para que tengas total entendimiento de los datos, cuando te lo mande quiero que me entregues el script para crear la tabla "esquema_sin_corregir" y el proceso para poblar todas las tablas

¡Perfecto! 🚀 mándame el CSV y con eso te armo:

- El script exacto para crear la tabla esquema_sin_corregir (con los tipos de datos correctos según tu archivo)
- 2. El pipeline completo para poblar las tablas normalizadas (Departamentos, Ciudades, Entidades, Procesos, etc.), incluyendo la conversión de duracion a días como acordamos.

Así evitamos errores de tipos y claves.

¿Quieres que prepare el script en **Oracle SQL** directamente (con CREATE TABLE, INSERT ... SELECT DISTINCT, MERGE, etc.), o prefieres que lo arme de forma genérica en **SQL estándar** y luego lo ajustamos a Oracle?

D B P O D L S

usa solo varchar ya que hubo errores con DATE, hazlo en oracle

Excelente \checkmark perfecto, entonces lo dejamos **todo en** VARCHAR2 (y NUMBER solo si estás 100% seguro que no da error). Te voy a dar:

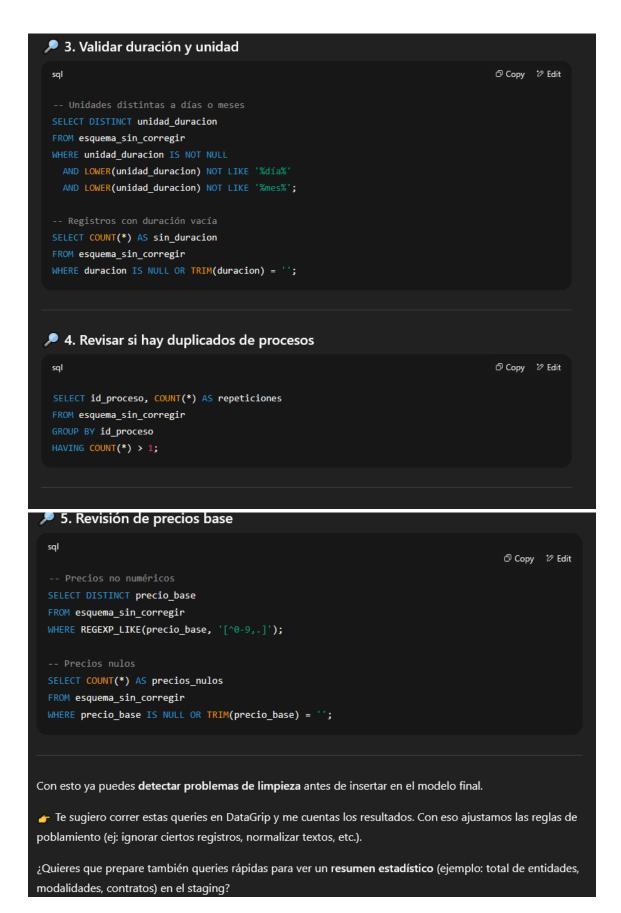
- 1. Creación de la tabla staging (esquema_sin_corregir) para poder subir tu CSV sin errores.
- 2. Creación de las tablas normalizadas (todas usando VARCHAR2 en lugar de DATE o INT , salvo NUMBER en IDs).
- 3. Proceso de carga desde la staging a las tablas normalizadas, incluyendo la conversión de duración a

Se verifican los datos y su calidad antes de poblar

Perfecto 🚀, vamos entonces con **auditoría de la tabla** esquema_sin_corregir **(staging)** antes de poblar el modelo normalizado.

Te voy a dejar consultas SQL que puedes correr en **DataGrip** → **Oracle** para responder cada una de las dudas:

```
🔎 1. Valores nulos en campos clave
                                                                                 sql
 SELECT COUNT(*) AS sin_nit
 FROM esquema_sin_corregir
 WHERE nit_entidad IS NULL OR TRIM(nit_entidad) = '';
 SELECT COUNT(*) AS sin_ciudad
 FROM esquema_sin_corregir
 WHERE ciudad_entidad IS NULL OR TRIM(ciudad_entidad) = '';
 -- Registros sin departamento
 SELECT COUNT(*) AS sin_departamento
 FROM esquema_sin_corregir
 WHERE departamento_entidad IS NULL OR TRIM(departamento_entidad) = '';
🔎 2. Inconsistencias: mismo NIT con distintos departamentos
                                                                                 sql
 SELECT nit_entidad,
        COUNT(DISTINCT departamento_entidad) AS departamentos_distintos
 FROM esquema_sin_corregir
 WHERE nit_entidad IS NOT NULL
 GROUP BY nit_entidad
 HAVING COUNT(DISTINCT departamento_entidad) > 1;
Aquí deberían aparecer cero filas, de lo contrario significa que el mismo NIT aparece en varios
```



Luego de verificar y resolver los errores se procede a poblar las tablas, en este proceso se encontraron varios errores:

[2025-08-18 11:22:05] [23000][1]

[2025-08-18 11:22:05] ORA-00001: Se ha violado la restricción única (MILU.SYS_C008547) para la tabla MILU.ENTIDADES en las columnas (NIT_ENTIDAD)

[2025-08-18 11:22:05] ORA-03301: (Detalles de ORA-00001) ya existe la fila con los valores de columna (NIT_ENTIDAD:899999034) [2025-08-18 11:22:05]

¡Bien visto \checkmark ! El error ORA-00001 te dice que intentaste insertar dos veces la misma entidad (mismo NIT) en la tabla Entidades .

Eso significa que en tu esquema_sin_corregir hay varias filas con el mismo nit_entidad pero con la misma ciudad/orden/centralizada, y como la PK es nit_entidad, Oracle lo rechaza.

Opciones para resolverlo

- Quedarse solo con una fila por NIT → usando DISTINCT nit_entidad.
 Esto es lo más directo porque cada NIT debería identificar a una sola entidad.
- 2. Si un mismo NIT puede tener diferentes ciudades/órdenes (cosa rara) → toca revisar la calidad de datos. Pero según tus verificaciones previas, no era el caso.
- Fix en el insert de Entidades

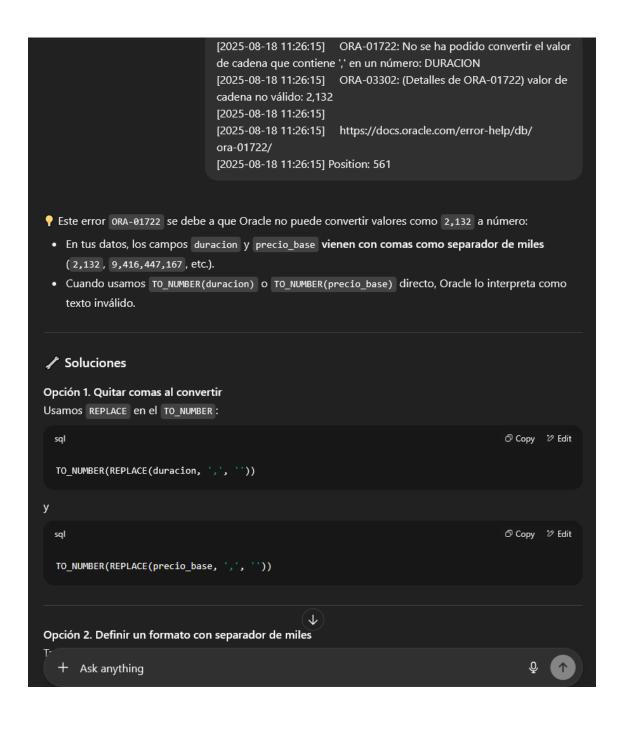
Cambia el INSERT a algo así:

```
INSERT INTO Entidades (nit_entidad, ciudad_id, orden_id, centralizada)

SELECT nit_entidad, ciudad_id, orden_id, centralizada

FROM (

SELECT TO_NUMBER(s.nit_entidad) AS nit_entidad,
```



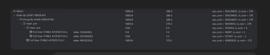


Nota: como que lo sospechaba entonces porque no lo arreglo 😡



```
Script corregido para Entidades
                                                                                      ெ Copy ७ Edit
  INSERT INTO Entidades (nit_entidad, ciudad_id, orden_id, centralizada)
  SELECT nit_entidad, ciudad_id, orden_id, centralizada
     SELECT TO NUMBER(s.nit entidad) AS nit entidad,
             MIN(c.id) AS ciudad_id,
             MIN(o.id) AS orden_id,
               WHEN LOWER(TRIM(MAX(s.entidad_centralizada))) LIKE 'centralizada%' THEN 'S'
               WHEN LOWER(TRIM(MAX(s.entidad_centralizada))) LIKE 'descentralizada%' THEN 'N'
             END AS centralizada
      FROM esquema_sin_corregir s
      JOIN Ciudades c ON c.descripcion = TRIM(s.ciudad_entidad)
      JOIN Departamentos d ON d.id = c.departamentos_id
                         AND d.descripcion = TRIM(s.departamento_entidad)
      JOIN Ordenes o ON o.descripcion = TRIM(s.orden_entidad)
      WHERE s.nit_entidad IS NOT NULL
     GROUP BY TO_NUMBER(s.nit_entidad)
👉 Esto debería dejar las entidades correctamente clasificadas en S (centralizada) o N (descentralizada).
¿Quieres que te prepare ya el script final completo de poblamiento con todas las correcciones (entidades
con centralizada bien, procesos con REPLACE para números y DISTINCT para evitar duplicados)?
```

Luego se pasa a las consultas, una vez diseñadas se piden algunas correcciones y ayudas con las posibles mejoras



este plan de ejecucion se podria mejorar?

Muy buena pregunta 👌.

El plan de ejecución que muestras está haciendo lo siguiente:

- Full Table Scan en CIUDADES, ENTIDADES y PROCESOS.
- Luego un Hash Join entre ellas.
- Finalmente un Group By (Hash Group By) y un Sort Order By para devolver el resultado.

Posibles mejoras

1. Índices en claves foráneas y columnas de join

Tus JOIN están en:

- p.nit_entidad = e.nit_entidad
- e.ciudad_id = c.id

Por lo tanto, deberías tener índices en:

```
create INDEX idx_procesos_nit_entidad ON Procesos(nit_entidad);
create INDEX idx_entidades_nit ON Entidades(nit_entidad); -- si no es PK
create INDEX idx_entidades_ciudad ON Entidades(ciudad_id);
create INDEX idx_ciudades_id ON Ciudades(id); -- si no es PK
```

📌 Con esto, Oracle podría usar Nested Loop + 븆 ex Access en lugar de Full Table Scan + Hash Join.

2. Estadísticas actualizadas

Si Oracle no tiene estadísticas recientes, asumirá que es más barato hacer Full Scan.

Asegúrate de correr:

```
BEGIN

DBMS_STATS.GATHER_TABLE_STATS('MILU', 'PROCESOS');

DBMS_STATS.GATHER_TABLE_STATS('MILU', 'ENTIDADES');

DBMS_STATS.GATHER_TABLE_STATS('MILU', 'CIUDADES');

END;

/
```

3. Particionar (si hay muchos datos)

Si Procesos tiene cientos de miles o millones de filas, considerar **particionar por ciudad_id o por año de fecha** para mejorar consultas de agregación.

4. Materialized View (si lo consultas mucho)

Si este reporte es muy frecuente, puedes crear una vista materializada precalculada:

```
CREATE MATERIALIZED VIEW mv_duracion_ciudad

BUILD IMMEDIATE

REFRESH COMPLETE ON DEMAND

AS

SELECT c.descripcion AS ciudad,

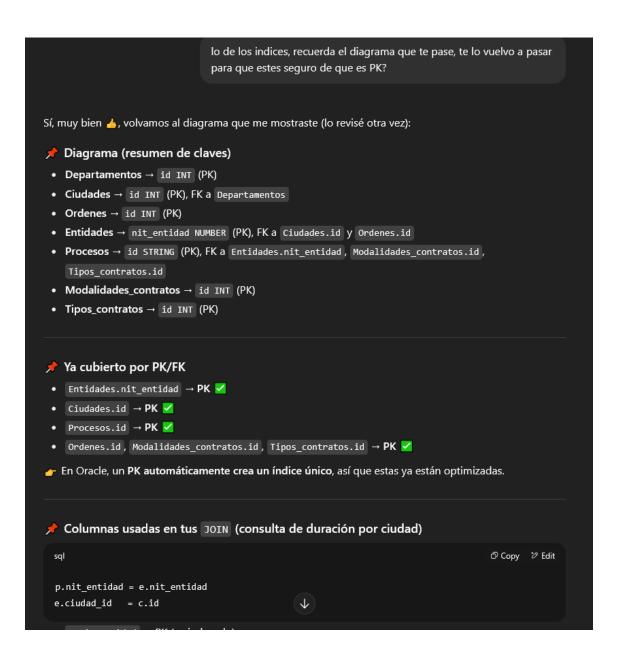
MIN(p.duracion) AS duracion_minima,

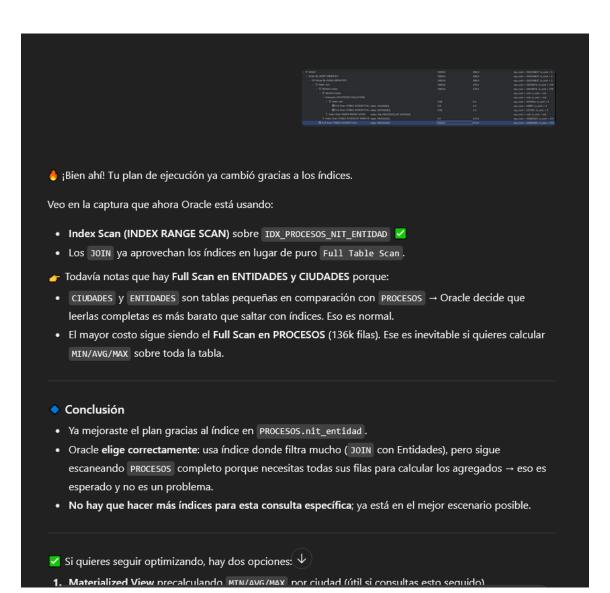
ROUND(AVG(p.duracion),2) AS duracion_promedio,

MAX(p.duracion) AS duracion_maxima

FROM Procesos p

JOIN Entidades e ON e.nit_entidad = p.nit_entidad
```





Segunda consulta:



como puedo mejorar este arbol de procesos

Muy buen punto ♠, lo que muestras en el plan de ejecución es **normal cuando usas CTE + Window Functions** en Oracle:

- Oracle genera tablas temporales (SYS_TEMP) para cada CTE y para los RANK(), COUNT() y
 agregaciones.
- Eso provoca muchos Full Table Scan sobre las tablas temporales.
- Por eso el costo total es alto (2308) comparado con tu primera consulta.

Observaciones del plan

- 1. PROCESOS sigue en Full Scan (136k filas) → esto es inevitable porque quieres estadísticas globales por mes.
- 2. Multiples SYS_TEMP \rightarrow cada GROUP BY y RANK() en las CTE genera materialización.
- **3.** Hash Join sobre Tipos y Modalidades → correcto, son tablas chicas y no afectan mucho.

Estrategias de mejora

- 1. Indices útiles
 - Un índice en la columna de fecha procesada (To_DATE(fecha) → o mejor una columna fecha_proceso DATE) ayudaría si filtras por rangos de fechas.
 - Ejemplo:

 \bigcirc

ත්

CREATE INDEX idx_procesos_fecha ON procesos (fecha); ெ Copy ७ Edit 2. Reducir materialización • Usa un solo CTE con todas las métricas, en lugar de 3 separados. Así Oracle genera menos SYS_TEMP. • Es decir, combina los conteos y los RANK() en un solo paso. 3. Materialized View (si el reporte es frecuente) • Si este reporte lo piden seguido, una vista materializada mensual precalculada bajaría el costo drásticamente. 4. Paralelismo • Para tablas de 100k+ filas, puedes activar paralelismo: ⑤ Copy 𝒯 Edit sql ALTER TABLE procesos PARALLEL 4; • O forzar en la consulta: ூ Copy ٷ Edit sql • Esto no baja el costo estimado, pero reduce el tiempo real. Resumiendo: • El árbol es "pesado" porque usas CTE + funciones ventana, y Oracle siempre crea esas SYS_TEMP. • Para mejorar: **1. Combinar CTEs** → menos tablas temporales. 2. Indexar fecha y claves foráneas. 3. Vista materializada mensual si el reporte es recurrente. 4. Paralelismo para ejecución más rápida.