

Documento IA

Nombre: Juan Jose Tamayo Ospina

ID: 000193632

1. Contexto sobre el proyecto

UT

Quiero que trabajemos sobre el siguiente contexto académico:

Estoy desarrollando un **proyecto de la materia Tópicos Avanzados de Base de Datos** en la Universidad Pontificia Bolivariana. El proyecto corresponde a un examen práctico y está enfocado en **índices y mejoras en el desempeño de consultas SQL**.

Origen de los datos: Los datos provienen de la plataforma de **Datos Abiertos de Colombia**, específicamente del dataset **SECOP II – Procesos de Contratación**. Para este proyecto se seleccionaron registros de los procesos de contratación realizados en el departamento de Antioquia entre enero y diciembre de 2024. El archivo de trabajo se llama `secop_data_antioquia_2024.zip` y contiene **143.044 filas** con 13 columnas relevantes ya preseleccionadas.

Formulación de requerimientos: El objetivo es construir y evaluar un modelo de base de datos relacional que cumpla con la **Tercera Forma Normal (3FN)** y que permita analizar el desempeño de consultas complejas. Para ello:

1. Se debe implementar un **modelo de datos inicial** (sin normalización) y un **modelo corregido** (estructurado y optimizado).
2. Aplicar estandarización de tablas y columnas, tipos de datos, claves primarias (PK), foráneas (FK), restricciones de unicidad (UK) e índices.
3. Generar planes de ejecución que permitan comparar el desempeño de consultas SQL con múltiples joins, Common Table Expressions (CTE) y Window Functions.

Las consultas principales son:

- * Diagnóstico de la **duración de contratos por ciudad** (mínimo, promedio y máximo en días).
- * Diagnóstico de la **relación del precio, modalidad de contratación y tipo de contrato por mes** (incluyendo conteos y estadísticas de precios).

Tu rol será **apoyarme en la construcción del modelo de datos, diseño de consultas, estrategias de optimización y análisis de planes de ejecución**, siempre dentro de este contexto académico. Por cierto el motor de bases de datos que voy a usar es postgresql.

Perfecto, entiendo el contexto de tu proyecto académico. Es un caso muy interesante trabajar con datos reales de contratación pública de SECOP II para análisis de desempeño en PostgreSQL. Te ayudaré en todas las fases del proyecto.

Para comenzar de manera estructurada, necesito conocer mejor la estructura actual de tus datos. ¿Podrías compartirme:

1. Estructura de datos actual:

- Los nombres de las 13 columnas que tienes en el dataset
- Algunos ejemplos de registros (puedes anonimizar datos sensibles)
- Los tipos de datos actuales o el formato en que vienen

2. Clarificación sobre el alcance:

- ¿Ya tienes los datos cargados en PostgreSQL o aún están en el archivo zip?
- ¿Hay alguna restricción específica sobre qué índices implementar?

Mientras tanto, puedo adelantarte la **estrategia general** que seguiremos:

Fase 1: Análisis y Modelado

- Modelo inicial (tabla única desnormalizada)
- Identificación de dependencias funcionales
- Diseño del modelo normalizado a 3FN

Fase 2: Implementación

- Creación de estructura optimizada
- Definición de PKs, FKs, UKs
- Estrategia de indexación por consultas objetivo

Fase 3: Optimización y Análisis

- Implementación de consultas complejas
- Generación y análisis de planes de ejecución
- Comparación de desempeño

Para los datos de contratación pública, típicamente esperaríamos entidades como:

- **Entidades contratantes** (municipios, departamentos)
- **Procesos de contratación** (información del proceso)
- **Contratos** (datos específicos del contrato)
- **Modalidades y tipos** (clasificaciones)

¿Podrías compartir la estructura de columnas para comenzar con el modelado?

2. Analisis del diagrama relacional



100Registros.csv

101 lines

CSV

JT

Ahora te voy a anexar dos elementos:

1. Una **muestra de 100 registros** del archivo original de datos.
2. Una **Imagen del diagrama relacional** que representa el diseño inicial del modelo de datos.

Con esta información, necesito que me ayudes en el siguiente punto del proyecto:


Etapla 1: Diseño e Implementación del modelo de datos (40%)

- * Analiza la estructura de los datos y el diagrama propuesto.
- * Evalúa si el modelo cumple con los principios de la **Tercera Forma Normal (3FN)**.
- * Identifica fortalezas y debilidades en el diseño actual.
- * Propón **sugerencias de mejora** concretas en:
 - * Normalización de tablas y columnas.
 - * Definición de claves primarias y foráneas.
 - * Restricciones de unicidad e índices.
 - * Tipado de datos y nomenclatura.
 - * Posibles relaciones adicionales entre entidades.

El objetivo es dejar un modelo relacional sólido y optimizado que sirva de base para las consultas SQL de las siguientes etapas del examen.

Perfecto! Ya tengo la información completa. Analicemos el modelo de datos paso a paso.

Análisis del Modelo de Datos SECOP II - Evaluación 3FN y Propuestas de Mejora
Document



Análisis Detallado del Modelo Actual

Después de revisar tu muestra de datos y el diagrama, identifico varios puntos críticos que requieren atención:

● Problemas Principales Detectados:

1. Violación 3FN en el modelo actual:

- La dependencia `nit_entidad → ciudad → departamento` crea redundancia
- Departamento siempre es "antioquía", generando datos innecesarios

2. Calidad de datos deficiente:

- Encoding UTF-8 mal manejado (caracteres como "medellín", "peñol")
- Fechas en formato inconsistente (MM/dd/yyyy vs dd/MM/yyyy)
- Modalidades como strings largos propensos a inconsistencias

3. Ausencia de catálogos normalizados:

- Modalidades y tipos como texto libre
- Unidades de duración sin tabla de referencia

🔗 Recomendaciones Inmediatas:

Para tu proyecto académico, te sugiero:

1. **Implementar el modelo normalizado** que diseñé en el documento
2. **Crear campos calculados** (`duración_dias_calculada`) para optimizar las consultas objetivo
3. **Aplicar la estrategia de indexación** específica para tus dos consultas principales
4. **Usar triggers** para automatizar cálculos y mantener integridad

📊 Próximos Pasos:

¿Te parece si comenzamos implementando este modelo en PostgreSQL? Necesitaría que me confirmes:

1. ¿Ya tienes la tabla original cargada en PostgreSQL?
2. ¿Prefieres que creamos scripts DDL completos primero?
3. ¿Quieres que enfoquemos la migración de datos paso a paso?

Este modelo te permitirá hacer comparaciones muy claras entre el esquema "sin normalizar" vs "normalizado y optimizado" para tu evaluación académica.



No requería de todo ese código, mi enfoque es educativo por lo que no deseo que me hagas todo el trabajo. Solo será necesario el código cuando te lo diga explícitamente.

Tienes razón, me disculpo por adelantarme. Mi rol debe ser guiarte en el análisis y comprensión, no resolver todo por ti.

Análisis Educativo del Modelo Actual

Evaluación 3FN - Preguntas para tu reflexión:

1. Dependencias Funcionales:

- ¿Qué relación ves entre `nit_entidad → ciudad_entidad → departamento_entidad`?
- ¿Por qué esto podría ser problemático para 3FN?

2. Redundancias Identificadas:

- Observa que "departamento" siempre es "antioquia" - ¿qué implica esto?
- Las modalidades como strings largos, ¿qué problemas de consistencia pueden generar?

3. Análisis del Diagrama Propuesto:

- ¿La separación en tablas elimina efectivamente las dependencias transitivas?
- ¿Falta alguna entidad que observes en los datos reales?

Fortalezas del modelo actual:

- Separación conceptual adecuada de entidades
- Identificación correcta de relaciones FK
- Estructura básica bien pensada

Debilidades críticas identificadas:

- Tabla "Departamentos" innecesaria (solo un valor)
- Falta normalización de modalidades y tipos
- Ausencia de tabla para unidades de duración
- Problemas de calidad de datos (encoding, fechas)

Preguntas clave para tu análisis:

1. ¿Cómo afectan estas debilidades al rendimiento de las consultas objetivo?
2. ¿Qué mejoras específicas propondrías para cumplir estrictamente con 3FN?
3. ¿Qué índices considerarías necesarios basándote en las consultas requeridas?

3. Calidad de datos



Me gustaría que te enfocaras en la parte de calidad de datos y normalización de los mismos

Análisis de Calidad de Datos y Normalización

Problemas de Calidad Identificados en los Datos:

1. Problemas de Encoding UTF-8:

```
medellín → medellĀn  
peñol → peÃ±ol  
cañasgordas → caÃ±asgordas
```

- **Impacto:** Inconsistencias en agrupaciones, problemas en joins
- **¿Cómo esto afecta tus consultas por ciudad?**

2. Inconsistencias en Formato de Fechas:

```
07/05/2024, 01/26/2024, 03/01/2024
```

- **Pregunta:** ¿Es MM/dd/yyyy o dd/MM/yyyy?
- **Riesgo:** Interpretaciones erróneas al convertir a DATE

3. Valores de Modalidades No Normalizados:

```
"contratación directa"  
"contratación régimen especial"  
"selección abreviada subasta inversa"
```

- **Problema:** Strings largos, posibles variaciones tipográficas
- **¿Qué pasaría si hay un typo en "contratación"?**

Análisis de Normalización Requerida:

Para Modalidades de Contratación:

- Observa las modalidades únicas en tu muestra
- ¿Cuántas modalidades diferentes identificas?
- ¿Hay patrones que sugieran una clasificación jerárquica?

Para Tipos de Contrato:

```
"prestación de servicios" (más frecuente)  
"decreto 092 de 2017"  
"compraventa"  
"suministros"  
"obra"
```

4. Consultas SQL

Scripts_Implementacion_Consultas.sql

13 lines

SQL

JT

Ahora te voy a anexar un **archivo .sql** con la implementación de dos consultas:

1. **Consulta 1:** Analizar la duración de los contratos por cada ciudad, mostrando la **duración mínima, promedio y máxima en días**.
2. **Consulta 2:** Analizar para cada mes la cantidad de procesos de contratación, la **modalidad de contratación más recurrente**, el **tipo de contrato más recurrente** y además los **precios mínimo, máximo y promedio**. Esta consulta está construida utilizando **CTE y Window Functions**.

Tu tarea será:

- * Revisar si la implementación de estas consultas es **correcta y eficiente**.
- * Indicar posibles **mejoras en la estructura de las consultas** para optimizar su ejecución.
- * Proponer **índices adecuados**, haciendo especial énfasis en **índices compuestos**, ya que los índices simples que he probado no mejoran el desempeño de manera significativa.
- * Explicar brevemente **por qué los índices propuestos** serían útiles en este caso, relacionándolos con las columnas y operaciones utilizadas en las consultas (joins, filtros, agrupaciones, etc.).

El objetivo es lograr que las consultas tengan un mejor plan de ejecución y aprovechen los índices de forma eficiente. No has código solo ideas

JT Ten en cuenta que realice una normalización y ya la duración está siempre en días, en ese caso que índices me recomiendas en especial compuestos pues ya intenté los simples y no aparenta funcionar (1 consulta)

Análisis de Índices Compuestos para Consulta 1

Comprensión del Path de Ejecución:

Con tu consulta actual:

```
sql
Procesos → JOIN Entidades → JOIN Ciudades → GROUP BY ciudad → Agregaciones
```

El problema con índices simples:

- PostgreSQL debe resolver 2 JOINS secuenciales
- Cada JOIN genera un conjunto intermedio de resultados
- Los índices simples no optimizan el "path completo"

Estrategia de Índices Compuestos:

Pregunta clave: ¿En qué orden debe procesar PostgreSQL para ser más eficiente?

Opción 1 - Optimizar el JOIN chain:

```
Índice en Entidades: (nit_entidad, ciudad_id)
```

Razonamiento:

- Cubre el JOIN con Procesos usando `nit_entidad`
- Incluye `ciudad_id` para el siguiente JOIN sin volver a la tabla
- PostgreSQL puede hacer "Index Only Scan"

Opción 2 - Optimizar para la agregación:

```
Índice en Procesos: (nit_entidad, duracion)
```

Razonamiento:

- Facilita el JOIN principal
- Incluye `duracion` para que las agregaciones (MIN/MAX/AVG) accedan directo al índice
- Evita accesos adicionales a la tabla Procesos

Opción 3 - Covering Index (más agresivo):

Análisis de las Consultas SQL - Enfoque Educativo

Revisión de la Consulta 1:

Estructura actual:

```
sql

SELECT c.descripcion, MIN(p.duracion), AVG(p.duracion), MAX(p.duracion)
FROM Procesos p
JOIN Entidades e ON e.nit_entidad = p.nit_entidad
JOIN Ciudades c ON c.id = e.ciudad_id
GROUP BY c.descripcion
```

Preguntas para tu análisis:

1. Problema de unidades mixtas:

- ¿Has considerado que tienes duraciones en "días" y "meses"?
- ¿Cómo esto afecta la validez de MIN/MAX/AVG?
- ¿Necesitas normalizar antes de calcular estadísticas?

2. Eficiencia del JOIN:

- ¿Es necesario pasar por la tabla Entidades para llegar a Ciudades?
- ¿Qué alternativas de diseño permitirían un acceso más directo?

Análisis de Performance:

Path de ejecución actual: `Procesos → Entidades → Ciudades`

Pregunta clave: Si tienes 143,044 procesos, ¿cuántos registros intermedios genera el primer JOIN antes de llegar a ciudades?

Propuesta de Índices Compuestos - Razonamiento:

Para la Consulta 1, considera:

1. ¿Qué columnas se usan en los JOINS?

- `p.nit_entidad` = `e.nit_entidad`
- `e.ciudad_id` = `c.id`

2. ¿Qué columnas se necesitan para el resultado?

- `p.duracion` (para agregaciones)
- `c.descripcion` (para agrupación)

3. ¿Cuál sería el índice compuesto ideal?

- **Reflexiona:** ¿Qué orden de columnas optimizaría tanto el JOIN como el acceso a duracion?

Vistas Materializadas - Concepto y Aplicación

¿Qué es una Vista Materializada?

Definición: Una vista materializada es una "**instantánea física**" de los resultados de una consulta que se almacena como una tabla real en disco.

Diferencia clave:

- **Vista normal:** Solo guarda la consulta, se ejecuta cada vez
- **Vista materializada:** Guarda los **resultados pre-cálculados**

¿Cuándo es Útil?

En tu caso específico:

- Consultas complejas con múltiples JOINS
- Cálculos de agregaciones (MIN, MAX, AVG) costosos
- Datos que **no cambian frecuentemente**
- Consultas que se ejecutan **repetidamente**

Ventajas vs Desventajas:

✅ Ventajas:

- **Performance:** Acceso directo, sin JOINS ni agregaciones en tiempo real
- **Predictibilidad:** Tiempo de respuesta constante
- **Menos carga:** Reduce procesamiento en consultas frecuentes

❌ Desventajas:

- **Espacio adicional:** Almacena datos duplicados
- **Sincronización:** Datos pueden estar desactualizados
- **Mantenimiento:** Requiere estrategia de actualización

Implementación para tu Consulta 1:

Concepto:

```
sql

-- En lugar de hacer los JOINS cada vez:
Procesos → Entidades → Ciudades → GROUP BY → Agregaciones

-- Pre-calcular y almacenar:
CREATE MATERIALIZED VIEW mv_duracion_por_ciudad AS
SELECT [...] -- Tu consulta completa
```

Implementación para tu Consulta 1:

Concepto:

```
sql
-- En lugar de hacer los JOINS cada vez:
Procesos → Entidades → Ciudades → GROUP BY → Agregaciones

-- Pre-calcular y almacenar:
CREATE MATERIALIZED VIEW mv_duracion_por_ciudad AS
SELECT [...] -- Tu consulta completa
```

Beneficios esperados:

- De 2,404 costo → **~1-5 costo** (simple SELECT de tabla)
- Sin JOINS, sin agregaciones en tiempo real

Estrategias de Actualización:

1. Manual:

```
sql
REFRESH MATERIALIZED VIEW mv_duracion_por_ciudad;
```

2. Automática (con triggers):

- Cuando se insertan/actualizan procesos
- Según horarios programados

3. Concurrente:

```
sql
REFRESH MATERIALIZED VIEW CONCURRENTLY mv_duracion_por_ciudad;
```

¿Cuándo Aplicar en tu Proyecto?

Pregunta clave: ¿Con qué frecuencia cambian los datos de SECOP II?

- Si es **diario/semanal**: Vista materializada muy útil
- Si es **cada minuto**: Mejor optimizar la consulta original

Para tu contexto académico:

- **Excelente** para demostrar técnicas de optimización
- Permite comparar performance: **sin MV vs con MV**
- Muestra comprensión de trade-offs

5. Decoracion Scripts y README.md

Script_implementation.sql
629 lines

SQL

UT ¿Comprendes el formato con el que se escribió el siguiente script en el apartado de los comentarios? solo dí sí o no

Sí.

El script está escrito con un formato muy estructurado y profesional en los comentarios, utilizando:

- Bloques de comentarios con líneas de igual (=) para separar secciones principales
- Encabezados detallados con información del proyecto, autor, universidad, etc.
- Secciones numeradas y organizadas jerárquicamente
- Comentarios descriptivos para cada tabla, función y procedimiento
- Uso de `COMMENT ON` para documentar objetos de base de datos
- Formato consistente con guiones (-) para subsecciones
- Explicaciones del propósito, características y relaciones de cada elemento

Es un excelente ejemplo de documentación técnica en SQL con alta legibilidad y organización.

Scripts_Implementacion_DB.sql
198 lines

SQL

Scripts_Implementacion_Consultas.sql
131 lines

SQL

UT Necesito que apliques lo mismo con estos dos archivos

Aquí está la versión corregida de ambos archivos aplicando el mismo formato estructurado y profesional del script original:

Scripts_Implementacion_DB_Corregido.sql
Code



README.md
153 lines

MD



Me puedes generar un nuevo README.md teniendo en cuenta como ejemplo el siguiente documento. Pero jo que el readme a crear es de este proyecto

README.md - Proyecto SECOP
Document



He creado un README.md completo y profesional para tu proyecto SECOP que mantiene el mismo estilo y estructura del ejemplo que proporcionaste. Los elementos principales incluyen:

Adaptaciones específicas para tu proyecto SECOP:

- Título enfocado en contratación pública en lugar de transporte
- Descripción del sistema SECOP y sus objetivos
- Estructura de datos adaptada a entidades públicas, modalidades de contratación, etc.
- Consultas específicas de análisis de duración por ciudad y estadísticas mensuales
- Esquemas "inicial" y "corregido" mencionados en tus scripts

Elementos que debes personalizar:

- Nombres y información de contacto de los integrantes del equipo
- Estadísticas específicas de tu base de datos (número de registros, entidades, etc.)
- Período exacto de los datos analizados
- Ruta específica de archivos CSV si los tienes